

TEAM DISCUSSION NOTE

결측치 처리 방식의 위험 비교

행 삭제 · 전월 값 대체 · shift(1) 적용 예시

대상: 법인가객 이탈 잠재 분석 프로젝트 | 문서 성격: 사전 위험 검토안

검토의 핵심 질문

“결측치를 어떻게 채울까?”보다

“어떤 처리 방식이 이탈 판정을 얼마나 왜곡할 수 있는가?”를 검토한다.

1. 이 분석에서 시간의 연속성이 중요한 이유

기획서는 월별 법인 기록으로 거래 변화와 이탈 상태를 판단한다. 따라서 달력상의 기간과 실제 계산에 사용한 기간이 일치해야 한다. [2]

분석 항목	기획서의 비교·판정 구조
입금 YoY 변화율	최근 3 개월 합계와 전년 동기 3 개월 합계 비교
규모 구분	판정 직전 12 개월의 평균 입금 규모
자동이체·외환	최근 3 개월의 금액·건수 또는 실적 확인
기획서상 “완전 이탈”	판정월 다음 3 개월 연속 기록 없음

2. 두 방식의 핵심 위험

방식	핵심 위험
A. 결측 행 삭제	월 행을 없앴 뒤 행 순서로 계산하면 시간 간격이 달라질 수 있다.
B. 전월 값 대체	확인하지 못한 월을 전월과 같다고 가정해 거래·보유 상태가 달라 보일 수 있다.

문서를 읽을 때의 전제

아래 22 개 항목은 **발생 가능한 오류 시나리오**이며 실제 데이터에서 확인된 오류가 아니다. 두 방법이 항상 잘못된다는 뜻도 아니다. 원문의 위험과 구분해야 할 적용 조건은 “보완 메모”로 표시했다.

원문 원칙: “거래 0 원”과 “기록 없음”은 다르다. 숫자 예시는 모두 설명용 가상값이다. [1][2]

01 결측 행 삭제 시 예상 위험

방법 A: 결측치가 있는 행을 배제하는 방식(Complete Case). 원문에서 제시한 위험 10 가지를 분석 영향과 함께 정리했다. [1]

번호	예상 문제	발생 상황	분석에 미치는 영향
1	t-1, t-2 가 끊김	중간 월을 삭제하면 달 간격과 행 간격이 달라진다.	shift(1)이 전월 대신 2 개월 전 값을 가져올 수 있다.
2	최근 3 개월 합계 왜곡	3 개월 중 결측인 달을 빼고 남은 2 개월만 합산한다.	이를 3 개월 합계로 사용하면 입금액을 과소평가할 수 있다.
3	전년 동기 비교 왜곡	올해와 작년의 유효 관측기간이 서로 달라질 수 있다.	YoY 변화율에 가짜 감소·증가가 생길 수 있다.
4	완전 이탈 판정 왜곡	월 행 삭제와 함께 원래 기록이 없던 월의 정보도 사라진다.	3 개월 연속 기록 없음 조건을 제대로 확인하기 어려워진다.
5	특정 법인의 과도한 탈락	결측이 많은 법인은 분석 가능한 기록이 줄어든다.	남은 법인만의 특성이 결과에 반영될 수 있다.
6	특정 집단의 과도한 탈락	특정 규모·업종 등의 결측이 많으면 해당 집단이 더 많이 빠진다.	업종·규모·등급별 비교가 왜곡될 수 있다.
7	12 개월 평균 계산 문제	일부 월이 빠진 합계·평균을 12 개월 지표로 사용한다.	규모 5 분위 분류가 달라질 수 있다.
8	상품 보유율 왜곡	좌수 등 일부 값의 결측 때문에 관련 법인의 기록 전체가 빠질 수 있다.	정상·이탈 잠재 고객의 상품 보유율 비교가 달라진다.
9	표본 수 감소	29 개 변수 중 하나라도 결측이면 행을 삭제하는 조건을 적용한다.	분석에 사용할 데이터가 크게 줄어든 수 있다.
10	미관측 신호 제거 가능성	“해당 월에 관측되지 않음”이라는 정보를 분석에서 잃는다.	이탈 판정에 활용하려던 정보가 제거될 수 있다.

보완 메모 | 삭제의 범위와 순서가 중요하다
이 위험은 원본 월 달력·관측 여부를 보존하지 않거나, 행을 삭제한 뒤 행 순서로 기간을 계산하는 경우에 특히 문제가 된다.
결측이 있는 법인을 모든 분석에서 통째로 제외해야 한다는 뜻은 아니다.

다음 페이지는 1 번 위험인 “달력상 전월 ≠ 삭제 후 직전 행”을 설명하는 예시다.

02 shift(1)은 왜 전월이 아닐 수 있나?

핵심 개념

이 예시의 groupby(...).shift(1)은 같은 법인 안에서 바로 이전 행의 값을 가져온다. 날짜를 읽어 “한 달 전” 값을 자동으로 찾는다는 뜻이 아니다. [1]

예시 조건: 법인 A의 기록이 월순으로 정렬되어 있고, 같은 법인·월의 중복 행은 없다고 가정한다.

① 원본 데이터

법인	월	입금액
A	1 월	100
A	2 월	120
A	3 월	NA
A	4 월	80

여기서 결측인 3 월 행을 통째로 삭제한 다음, 아래 코드를 적용한다고 가정한다.

```
df["전월입금액"] = df.groupby("법인 ID")["입금액"].shift(1)
```

② 3 월 행을 삭제한 뒤 shift(1)을 적용

월	입금액	shift(1) 결과	값을 가져온 월
1 월	100	NA	이전 행 없음
2 월	120	100	1 월
4 월	80	120	2 월 → 전월이 아님

4 월의 실제 전월은 3 월이다. 그러나 3 월 행이 없어졌기 때문에 4 월의 직전 행은 2 월이 된다. 코드가 실행되더라도 “전월입금액”이라는 변수의 의미는 틀릴 수 있다.

③ 3 월 행을 유지한 뒤 shift(1)을 적용

월	입금액	shift(1) 결과	해석
1 월	100	NA	이전 행 없음
2 월	120	100	1 월 값
3 월	NA	120	2 월 값
4 월	80	NA	3 월은 있지만 값은 모름

월을 유지한 결과가 뜻하는 것: “4 월의 전월은 3 월이며, 3 월의 입금액은 알 수 없다.”

결론: 월별 시차를 만들 때는 달력의 연속성을 먼저 확보해야 한다. 전월 값이 결측인 것과, 다른 달의 값을 전월로 가져오는 것은 서로 다른 문제다.

03 전월 값 대체 시 예상 위험

방법 B: 결측치를 이전 값으로 채우는 방식(Forward Fill). 원문에서 제시한 위험 12 가지를 정리했다. 아래 항목은 대체값을 실제 관측값처럼 사용하는 경우의 위험을 설명한다. [1]

번호	예상 문제	발생 상황	분석에 미치는 영향
1	가짜 거래 생성	결측인 3 월에 2 월 입금액을 복사한다.	확인하지 못한 월에도 동일한 거래가 있었다고 처리한다.
2	감소폭 축소	실제로 감소했을 가능성이 있는 월에 이전 값을 유지한다.	이탈 잠재 고객을 정상으로 잘못 분류할 수 있다.
3	완전 이탈을 숨길 가능성	연속 미관측 월을 채운 뒤 원본 관측 여부를 구분하지 않는다.	기록이 없던 고객을 계속 관측된 고객처럼 판단할 수 있다.
4	3 개월 합계 부풀림 가능성	한 달의 값이 다음 달에도 반복해서 들어간다.	대체값이 실제보다 크면 최근 3 개월 합계가 과대평가된다.
5	YoY 변화율 왜곡	올해 또는 작년 합계에 복사한 값이 포함된다.	-30% 이탈 잠재 기준을 충족하는지가 바뀔 수 있다.
6	자동이체 소멸 감지 실패	이전 자동이체 금액·건수를 계속 유지한다.	실제로 소멸했다면 이를 유지로 판단할 수 있다.
7	외환거래 여부 왜곡	과거 수출입 실적을 결측월에 복사한다.	실제 거래가 없던 월을 거래가 있는 월로 처리할 수 있다.
8	상품 해지 감지 실패	과거 좌수·개수로 현재의 결측을 채운다.	해지된 상품을 계속 보유한 것으로 볼 수 있다.
9	한도 소진율 왜곡	한도·대출잔액에 과거 값을 사용한다.	현재 대출 상태의 변화가 제대로 반영되지 않을 수 있다.
10	장기 결측 시 오류 누적	한 번의 값이 여러 달에 걸쳐 복제된다.	오래된 상태가 장기간 유지된 것처럼 보일 수 있다.
11	변동성의 인위적 감소	동일한 값이 이어지는 구간을 만든다.	대체 구간의 실제 변화가 가려져 안정적으로 보일 수 있다.
12	금융행태집단 분류 오류	상품·외환·대출 상태를 과거 상태로 유지한다.	집단 구분과 집단별 상품 제안 대상이 달라질 수 있다.

보완 메모: “합계 부풀림”과 “감소폭 축소”는 가능한 방향의 예시다. 실제 결측월의 값은 알 수 없으므로, 전월 대체가 항상 과대추정하거나 항상 정상 판정을 늘린다고 단정할 수는 없다.

04 전월 대체 예시와 해석 시 유의사항

원문 예시는 “1 월 100 → 2 월 80 → 3~5 월 NA”가 전월 대체 후 어떻게 달라지는지 보여준다. [1]

예시 해석을 위한 보완 조건

여기서는 3~5 월이 입금액 한 칸만 결측인 상태가 아니라, 해당 법인의 원본 월 기록 자체가 없는 상태라고 가정한다. 이 구분이 있어야 기획서의 미관측 조건과 연결할 수 있다.

월	원본 관측여부	원본 입금액	전월 대체 후
1 월	1	100	100
2 월	1	80	80
3 월	0	NA	80
4 월	0	NA	80
5 월	0	NA	80

원본: 100 → 80 → NA → NA → NA
대체 후: 100 → 80 → 80 → 80 → 80

원문에서 우려한 상황

2 월을 판정월로 두면 3~5 월은 “다음 3 개월 연속 기록 없음”이라는 정보에 해당한다. 그런데 채워진 금액만 보고 기록 유무를 판단하면, 원래 관측되지 않은 월에도 거래가 계속된 것처럼 해석할 수 있다. [2]

보완 메모 1 | 관측 여부를 별도로 보존하면

표의 원본 관측여부 0 은 금액을 대체해도 0 으로 유지해야 한다. 이를 별도로 사용하면 “기록이 없었던 달”은 계속 확인할 수 있다. 따라서 전월 대체 자체가 반드시 미관측 정보를 없애는 것은 아니다.

보완 메모 2 | 거래금액 분석의 위험은 남는다

원본 관측 여부를 남기더라도, 대체한 80 을 입금 합계·YoY·자동이체·외환 지표에 사용하면 그 계산에는 “같은 값이 유지됐다”는 가정이 들어간다. 미관측 정보의 보존과 금액 지표의 왜곡은 별도로 확인해야 한다.

두 방법의 차이

행 삭제: 없는 달을 제거한 결과, 시간 관계를 잘못 계산할 위험.

전월 대체: 알 수 없는 달에 과거 값을 넣어, 거래 상태를 잘못 해석할 위험.

용어 주의: “완전 이탈”은 기획서에서 정한 명칭이다. 3 개월 연속 미관측이 실제 거래 종료를 확인한 결과와 동일하다는 근거는 이 자료에 제시되어 있지 않다.

05 비교 실험 제안과 팀 논의 사항

원문에서는 A·B 두 방식과 함께 C 안을 기준으로 두고, 결측 처리에 따라 결과가 얼마나 바뀌는지 비교할 것을 제안했다. 이는 실제 비교 결과가 아니라 **민감도 분석 계획**이다. [1]

안	원문에서 제안한 처리 방식
A 안	결측치가 있는 행 배제
B 안	결측치를 전월 값으로 대체
C 안 · 기준 제안	월 행 유지 + 결측은 NA 유지 + 원본 관측여부 별도 생성

원문에서 제안한 비교 항목 6 가지

비교 항목	확인할 내용
① 분석 가능 법인 수	어떤 처리에서 얼마나 많은 법인이 분석에 포함되는가
② 이탈 잠재 고객 수	결측 처리에 따라 -30% 기준의 판정이 얼마나 달라지는가
③ 기획서상 완전 이탈 수	원본 미관측 정보에 따른 판정이 보존되는가
④ 정상 고객 수	정상으로 분류되는 법인 수가 어떻게 달라지는가
⑤ YoY 변화율 분포	변화율의 분포와 감소 폭이 얼마나 달라지는가
⑥ 금융형태집단 분포	결측 처리에 따라 소속 집단이 바뀌는가

공유용 보완 | 비교 실험의 공통 전제

세 안 모두 원본 관측 여부, 법인·월 기준, 분석 기간, 지표 정의를 동일하게 보존한다. A 안도 원본 달력을 따로 남기고, B 안도 보완된 값을 관측으로 바꾸지 않는다. 잘못된 시차 계산으로 생긴 오류를 처리 방식의 차이로 비교해서는 안 된다.

추가 확인: C 안은 NA를 남기는 데서 끝나지 않는다. 필요한 월이 부족한 지표는 “판정 불가”로 구분해야 한다. 비교 시에는 원문의 6 개 항목 외에 **판정 불가 수·분모와 제외 현황**도 함께 기록하는 것이 좋다.

팀 논의의 결론

일괄 삭제 또는 일괄 대체를 바로 채택하기보다, 시간축과 원본 관측 정보를 보존한 상태에서 각 방식의 적용 범위를 정하고 **결과 차이를 확인**한다.

자료 범위와 출처

[1] 사용자가 공유용으로 제공한 대화 원문: “결측 행 배제·전월 값 대체의 예상 위험” 및 “shift(1) 설명”. 위험 10 개·12 개, 예시 숫자, A/B/C 비교 제안의 정리 기준.

[2] 「법인고객 이탈 잠재 분석 — 데이터 전처리 기획서」, 2026.09.23. 02 장 ‘데이터에 숨어 있는 함정’, 04 장 ‘빈 달 채우기’, 05 장 ‘파생지표’ 참고. 업로드 파일: 전처리기획서_우영.html.

편집 범위: 대화체를 팀 검토 문체로 정리했다. “보완 메모”는 앞선 논의에서 구분한 적용 조건·해석 한계를 명시한 부분이며, 별도 외부 조사나 원자료 분석 결과는 아니다.